

Контролируемая генерация текста с учетом уровня идиоматичности

Жигулина Александра, 3 курс, Фундаментальная и компьютерная лингвистика

Научный руководитель: О. Н. Ляшевская

Введение

То, насколько хорошо LLM умеют понимать и генерировать образный текст, до сих пор изучено слабо. Большинство работ в области figurative language detection/generation фокусируются на одном или нескольких явлениях, причем рассматривают их чаще всего в контексте предложений. При этом ситуации, когда несколько явлений встречаются в контексте одновременно, а одно явление принадлежит более чем одному предложению, упускаются из виду.

В работе предлагается бенчмарк для оценки способности моделей к контролируемой генерации образного (или идиоматичного) текста для заданного уровня генерации. Учитывая ограничения, указанные выше, бенчмарк основывается на датасете, состоящем из буквальных версий коротких образных текстов.

Создание датасета

Выбор текстов

Было собрано 84 текста двух типов: 42 художественных и 42 новостных.

При выборе текстов учитывались следующие аспекты:

- Стилистическое разнообразие (≤ 2 текстов на автора/издательство)
- Тематическое разнообразие (тексты из разных произведений/разных частей одного произведения)
- Вариативность по функционально-смысловым типам речи (присутствует описание, повествование, рассуждение, а также диалог)

Размер текстов — 100-400 слов. Такой размер позволяет выбирать законченные по смыслу фрагменты, оценивать среднюю плотность идиом текста и включать идиомы, развернутые на несколько предложений.

Эксперименты с датасетом mini

Цели датасета mini: исследовать работу моделей с жанровым разнообразием, протестировать разные типы SOTA-моделей и техники промптинга для буквализации. Всего в датасете 10 текстов (художественная проза — 4 фрагмента, сказки — 2, учебно-научные тексты — 2, техническое описание — 1, новостная заметка — 1)

- Протестированные модели:
 - (русские) YandexGPT 5.1 Pro и GigaChat 2 Max
 - (зарубежные) GPT-5.4, Claude 4.6 Opus, DeepSeek R1, Gemini 3.1 Pro
- Всего 5 промптов: базовый, с ролью, с прагматической концепцией идиоматичности, с описанием единиц, комбинированный. Каждый, кроме последнего, применялся в формате zero-shot, one-shot, few-shot.
- Модели хорошо справлялись с техническими текстами, но были проблемы с жаргонизмами. В художественных текстах модели оставляют 3-5 идиоматичных конструкций. При этом примеры не дают заметного улучшения.

- Самые сложные явления для моделей: глаголы фиктивного движения, жанровые формулы, завуалированное описание эмоций. Эти категории учтены в итоговом промпте.
- Лучшие модели: Claude 4.6 Opus и GigaChat 2 Max.

Обработка

[Этап разметки]

- 1) Вручную выделены все идиоматичные выражения в исходных текстах. Выделялись минимальные связные единицы, которые можно считать образными. При возникновении сложностей использовались НКРЯ и Google Ngram Viewer.

Фразеологический	Устойчивые сочетания
Семантический (тропы)	Метафоры, метонимии, олицетворения, сравнения
Словообразовательный	Окказионализмы
Синтаксический	Некомпозициональность в грамматической схеме/структуре предложения
Прагматический	Жанровые клише, речевые формулы, риторические вопросы/восклицания, маркеры мыслительного процесса
Дискурсивный	Сквозные образы, метанарративы, прецедентные феномены (отсылки к культуре)
Исключения	Стилистически маркированная лексика — диминутивы, просторечия, изолированные эпитеты Архаичная лексика — если была естественна на момент использования (кроме намеренной стилизации) Экспрессивный синтаксис — инверсия, параллелизм, антитеза, авторский синтаксис

- 2) Рассчитано значение **idiomatic_density** (отношение числа слов в исходном тексте к числу слов в выделенных идиоматичных выражениях).

[Этап буквализации]

- 1) Для каждого текста создана буквальная версия, в которой все образные выражения трактуются как можно ближе к их букальному значению.
- 2) Текст и выделенные в нем выражения были передан модели GigaChat-2-Max.
- 3) Оставшиеся идиомы и ошибки интерпретации текста редактировались вручную.

Итоговый датасет

[Пример одного объекта датасета (текст сокращен)]

id	author	source	link	year_of_creation	text_domen
6	Мариам Петросян	Дом, в котором...		2009	художественный

original_text	idiomatic_expressions	literal_version	len_ original	len_ idiom	idiomatic_ density
Дом стоит на окраине города. В месте, называемом Расческами. Длинные многоэтажки здесь выстроены зубчатыми рядами с промежутками квадратнобетонных дворов – предполагаемыми местами игр молодых «расчесочников». Зубья белы, многоглазы и похожи один на другой. Там, где они еще не выросли, – обнесенные заборами пустыри. Труха снесенных домов, гнездилища крыс и бродячих собак гораздо более интересны молодым «расчесочникам», чем их собственные дворы – интервалы между зубьями.	Длинные многоэтажки здесь выстроены зубчатыми рядами с промежутками квадратно-бетонных дворов Зубья белы, многоглазы и похожи один на другой где они еще не выросли между двумя мирами – зубцов и пустырей	Дом расположен на краю города, в районе, известном как Расчески. Здесь стоят длинные многоквартирные здания, расположенные параллельными рядами с интервалами, занятыми бетонными дворами, предназначенными для игр юных местных жителей. Здания белые, имеют многочисленные окна и выглядят одинаково. Между зданиями находятся пустующие участки земли, окружённые забором. Остатки разрушенных строений привлекают больше внимания детей, чем эти дворы.	194	69	0.3557

[Уровни идиоматичности]

Выделено три уровня идиоматичности — **низкий, средний и высокий**. Границы уровней опираются на разделение по квантилям idiomatic_density (i_d):

- низкий: $i_d \leq 0.12$
- средний: $0.12 < i_d \leq 0.38$
- высокий: $0.38 < i_d$




Рис. 1. Ящик с усами для распределения показателей плотности идиоматичности текстов обоих типов.

Бенчмаркинг

Дизайн

[Модели]

Для бенчмаркинга были выбраны модели Qwen2.5-3B, Qwen2.5-7B, Qwen2.5-14B и Mistral-7B. Такой выбор позволяет сравнить влияние на результат двух параметров: размера модели и ее архитектуры и особенностей обучения.

[Технические детали]


- Доступ к моделям локально через Ollama
- Температура генерации понижена с 0.8 до 0.75 для стабильности (меньше неграмматичных и несвязанных с текстом по смыслу идиом).
- Особенности промптинга:

- Примеры в промпте (one-shot/few-shot) вызывали путаницу и поэтому не использовались (модели смешивали примеры с целевым текстом примерно в 20% генераций).
- Запрет конструкций “X как Y” добавлен в итоговый промпт (модели злоупотребляли сравнениями).
- Финальный промпт включает задачу указать процент идиом (без их выделения).

[LLM-as-a-judge]

1. Грамматическая корректность (0-5)
2. Плавность и естественность речи (0-5)
3. Осмысленность употребления идиоматических выражений (0-5)
4. Вариативность по типам идиом (0-5)
5. Общая образность и насыщенность текста идиомами (0-2)
6. Список всех идиоматичных выражений, которые выделил судья.

Рис. 2. Диаграммы рассеяния с линией регрессии и 95% доверительным интервалом, отражающие корреляцию между оценками идиоматической плотности аннотатора и модели.



[Метрики]

Автоматическая оценка идиоматичности	Автоматическая оценка качества генерации (сохранение контекста)
Perplexity Среднее арифметическое перплексии всех токенов. Для одного токена рассчитывается как $PPL = \exp(\text{Loss})$.	BERTScore (F1) Косинусное сходство между контекстуальными эмбедингами токенов текстов. Позволяет учитывать перефразирования и синонимичные замены, недоступные n-граммным метрикам. Для расчета использовался BERTScorer библиотеки bert_score. (Zhang et al., 2020)
Concreteness/Abstractness Среднее арифметическое индекса абстрактности для всех слов.	BLEURT Нейросетевая метрика, дообученная на человеческих оценках. Расчет через bleurt_pytorch (модель lucadiliello/BLEURT-20-D12).

Значения индекса берутся из словаря конкретности/абстрактности для русского языка. (Solovyev et al., 2022)	(Sellam et al., 2020)
Word frequency Средняя частота слов текста (рассчет через библиотеку wordfreq).	COMET Нейросетевая метрика, дообученная на человеческих оценках. Рассчет через comet (модель Unbabel/wmt22-comet-da). (Rei et al., 2020)
Linear Semantic Coherence Для каждого глагола в текста в окне из 5 слов рассчитывается среднее косинусное сходство всех слов включая и исключая его. (Panicheva & Badryzlova, 2017)	METEOR Оценивает лексическое совпадение между двумя текстами. Учитывает синонимию и стемминг, объединяет классические метрики BLEU (точность) и ROUGE (полнота). Для расчета использовался метод <code>nltk.translate.meteor_score</code> .
Sentiment Предсказание тональности текста (позитивная, негативная, нейтральная). Расчет с помощью классификатора на основе модели BERT.	WMD (Word Mover's Distance) Минимальное совокупное расстояние для транспорта эмбедингов слов из одного текста в другой. Метрика = $1/(1 + \text{wmdistance})$, где $\text{wmdistance} = 0$ при полном совпадении. Рассчет через встроенный метод класса KeyedVectors в библиотеке Gensim.

Эксперимент

[Создание бейзлайна]

Исходные (образные) тексты датасета `taxi` пропущены через полный пайплайн оценки. Получены значения метрик для дальнейшего анализа.

[Генерация]

Для каждой модели было сгенерировано по 3 версии каждого текста из датасета (низкий, средний и высокий уровень идиоматичности), всего — 1008 текстов. При ошибках (другой язык, потеря части текста) проводилась повторная генерация.

[Оценка судьи]

Сгенерированные тексты оценивались LLM-судьей. 17 текстов были отклонены из-за несоответствия гайдлайнам модели-оценщика и не анализировались далее.

[Расчет автоматических метрик]

На оставшихся текстах были рассчитаны автоматические метрики сохранения качества контекста и образности.

Результаты

[Примеры генерации]

Мышь с ярко-рыжими волосами в сравнении с обычной лабораторной мышью выглядит как карикатурная копия. Первый тип отличается от второго не только цветом шерсти, но и её густой, волнующей структурой — волны которой напоминают узоры на облаках, а волосы имеют чёткую форму, словно они были выкованы мастером по золоту. Второй тип, как известно из древних легенд, был создан искусным образом для демонстрации красоты и удивительной гладкой шкурки, на которой не видны даже самые мелкие вши. Исследователи подошли к вопросу с оптимизмом и рациональностью: вместо того чтобы воспроизводить внешний вид мамонта путем прямого переноса генов, они решили тщательно исследовать их влияние на организм мыши. (Qwen2.5-7B, высокий уровень)

В дебрях биологической лаборатории скрыта история о двойнике древнейших обитателей земли. Наша героиня, изящная мышь с косматыми гривами, на фоне своих молочных собратьев выглядит как будто сошедшая с палеонтологической страницы истории. Сверкающая рыжими бликами шерсть и вихри нежных волос словно переносят нас в эпоху ледникового периода, когда исполинские мамонты ступали по земле с величественной грацией. Но эта необычная мышь — плод современных научных изысканий и инновационных технологий, а не простой перенос генов предков в наше время, как можно было бы подумать. (Qwen2.5-14B, высокий уровень)

[Анализ числовых значений]

Таблица 1. Результаты оценки судьи. Уровни идиоматичности обозначены числами: 0 – низкий, 1 – средний, 2 – высокий.

	level	grammar	fluency	naturalness	idiomacy	idiom_diversity	idiomatic_density (judge)
Original texts	0	5.0000	5.0000	4.9524	0.381	1.0952	0.0071
	1	4.9524	4.9286	4.9524	1.500 (+ 1.119)	4.0476 (+ 2.9524)	0.0887
	2	5.0000	5.0000	5.0000	2.000 (+ 1.619)	5.0000 (+ 3.9048)	0.1601
Mistral-7B	0	4.7831	4.7229	4.6988	1.2651	3.2289	0.1186
	1	4.7805	4.6341	4.5488	1.3415 (+ 0.0764)	3.3293 (+ 1.004)	0.1205
	2	4.7927	4.7317	4.6951	1.4878 (+ 0.2227)	3.7805 (+ 0.5516)	0.1397
Qwen2.5-14B	0	5.0000	4.9878	4.9756	1.1707	3.1707	0.1053
	1	4.9878	4.9634	4.9634	1.4390 (+ 0.2683)	3.7317 (+ 0.561)	0.1361
	2	4.9878	4.9634	4.9512	1.8659 (+ 0.6952)	4.6341 (+ 1.4634)	0.1865
Qwen2.5-7B	0	4.9634	4.9390	4.8659	1.2439	3.2805	0.1167
	1	4.9759	4.9639	4.9398	1.3494 (+ 0.1055)	3.5181 (+ 0.2376)	0.1241
	2	4.7857	4.6786	4.6071	1.3690 (+ 0.1251)	3.3214 (+ 0.0409)	0.1366
Qwen2.5-3B	0	4.8313	4.8072	4.7590	1.0964	2.8434	0.0988
	1	4.8690	4.7976	4.7738	1.1071 (+ 0.0107)	2.8333 (+ 0.0101)	0.0977
	2	4.7439	4.7683	4.7317	1.1707 (+ 0.0743)	2.9024 (+ 0.059)	0.1149

Основные наблюдения:

1. Оценки **grammar**, **fluency** и **naturalness** изменяются по-разному. Для оригинальных текстов они немного “проседают” на среднем уровне. Похожим образом ведут себя оценки Mistral-7B. У моделей Qwen2.5 присутствует тенденция к снижению значений с повышением уровня, хотя порой они показывают неожиданно высокое качество на среднем уровне.
2. Минимальное значение **idiomacy** моделей выше 1, тогда как для оригинальных текстов оно равно 0.381
3. С повышением уровня значение **idiomacy** увеличивается у всех моделей. Самая большая разница между 0 и 2 уровнем у модели Qwen2.5-14B (+ 0.6952), следом идет Mistral-7B (+ 0.2227). Хуже всех справилась самая маленькая модель Qwen2.5-3B (+ 0.0743). При этом для оригинальных текстов прирост **idiomacy** равен 1.619.
4. Минимальное значение **idiom_diversity** моделей — 2.8434, его показывает Qwen2.5-3B на низком уровне идиоматичности. При этом минимальное значение на оригинальных текстах равно 1.0952.
5. С повышением уровня значение **idiom_diversity** возрастает у большинства моделей (максимально — на 1.4634 у Qwen2.5-14B, Mistral-7B снова на втором месте).
6. Qwen2.5-7B проявляет неожиданную динамику — его **idiom_diversity** возрастает на среднем уровне и вновь снижается на высоком.
7. **idiomatic_density (judge)** особенно сильно занижена для оригинальных текстов по сравнению с **idiomacy**, что косвенно указывает на более высокую сложность и вписанность в контекст идиом, придуманных человеком.

Таблица 2. Результаты расчета автоматических метрик сохранения контекста.

	BERTScore (F1)	BLEURT	COMET	METEOR	WMD (Word Mover's Distance)
Original texts	0.7378	0.2956	0.8555	0.2704	0.6950
Mistral-7B	0.8370	0.4018	0.8547	0.6372	0.8199
Qwen2.5-14B	0.7757	0.3246	0.8525	0.4238	0.7528
Qwen2.5-7B	0.8141	0.4443	0.8424	0.5072	0.7863
Qwen2.5-3B	0.8157	0.4185	0.8494	0.5389	0.7962

Основные наблюдения:

1. Среди моделей Mistral-7B показывает самый высокий результат по всем метрикам, кроме BLEURT. Qwen2.5-14B напротив показывает самые низкие результаты по значениям метрик (кроме COMET).
2. Результаты метрик для оригинальных текстов ниже, чем результаты для сгенерированных моделями (кроме COMET).

Таблица 3. Результаты расчета автоматических метрик идиоматичности.

	level	Perplexity	Concreteness/ abstractness	Word frequency	Linear Semantic Coherence	Sentiment (negative/neutral/positive)
--	-------	------------	-------------------------------	-------------------	------------------------------	--

Original texts	0	6.5658	2.7923	4.1871	-0.0045	0.6/0.24/0.15
	1	10.8805	2.6185	4.0678	-0.0032	
	2	15.7276	2.5319	3.8586	-0.0028	
Mistral-7B	0	8.8001	2.8457	4.1771	-0.0036	0.47/0.37/0.17
	1	8.6707	2.8392	4.1972	-0.0042	
	2	8.8952	2.8426	4.1907	-0.0036	
Qwen2.5-14B	0	7.9191	2.8352	4.1637	-0.0036	0.5/0.3/0.2
	1	8.5078	2.8421	4.1549	-0.0038	
	2	9.5914	2.8219	4.0908	-0.0042	
Qwen2.5-7B	0	9.2672	2.8000	4.1700	-0.0036	0.45/0.38/0.17
	1	9.0146	2.8002	4.1728	-0.0046	
	2	8.9617	2.8324	4.1701	-0.0040	
Qwen2.5-3B	0	8.6338	2.8305	4.1341	-0.0042	0.42/0.42/0.15
	1	9.1170	2.8136	4.1315	-0.0039	
	2	9.2323	2.8727	4.1514	-0.0031	

Основные наблюдения:

1. **Perplexity** оригинальных текстов значительно выше, чем у сгенерированных, причем значение метрики растет при переходе к более высоким уровням идиоматичности.
2. Метрика **concreteness/abstractness** показывает неожиданную динамику: абстрактность оригинального текста и текста модели Mistral-7B выше на низком уровне, у Qwen2.5-14B на среднем и у Qwen2.5-7B и Qwen2.5-3B на высоком.
3. Только у человека значение средней частоты слов (**word frequency**) опускается ниже
4. Модель Qwen2.5-14B проявляет похожую динамику (стабильное снижение), но доходит только до 4.0908 при похожих исходных значениях. Qwen2.5-3B проявляет обратную динамику, а Mistral-7B и Qwen2.5-7B отличаются более высокими значениями на среднем уровне.
4. Метрика **Linear Semantic Coherence** показывает слабую зависимость от уровня идиоматичности.
5. Среди оригинальных текстов меньше всего нейтральных. При этом Qwen2.5-3B, Qwen2.5-7B и Mistral-7B заметно завышают эти значения, а вот Qwen2.5-14B находится довольно близко к значениям оригиналов.

Ссылка на гитхаб работы

<https://github.com/SereneScarecrow/coursework-idiomacy-ctg>

Источники, упомянутые в хэндауте

НКРЯ — <https://ruscorpora.ru/>

- Panicheva P., Badryzlova Y. Distributional semantic features in Russian verbal metaphor identification // Компьютерная лингвистика и интеллектуальные технологии. 2017. Вып. 1. С. 179–190.
- Rei R., Stewart C., Farinha A. C., Lavie A. COMET: A neural framework for MT evaluation // Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020. P. 2685–2702.
- Sellam T., Das D., Parikh A. BLEURT: Learning robust metrics for text generation // Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020. P. 7881–7892.
- Solovyev V. D., Volskaya Y. A., Andreeva M. I., Zaikin A. A. Russian dictionary with concreteness/abstractness indices // Russian Journal of Linguistics. 2022. T. 26. № 2. С. 515–549.
- Zhang T., Kishore V., Wu F., Weinberger K. Q., Artzi Y. BERTScore: Evaluating text generation with BERT // International Conference on Learning Representations. 2020.